理解 LoRA

https://github.com/microsoft/LoRA

该仓库包含最小化 LoRA 实现，以及论文 *LoRA: Low-Rank Adaptation of Large Language Models* 作者 *Edward J. Hu* 对LoRA的视频解读。

模型与显存占用

Transformer Math 101 *https://blog.eleuther.ai/transformer-math/*

```
Total memory = model size + kv-cache + activation memory + optimizer/grad memory + cuda
```

1. Model size = 这是 .bin 文件大小（如果是 Q8 量化，除以 2；如果是 Q4 量化，除以 4）。
2. KV-Cache = KV（键值）向量占用的内存。大小 = 每层 (2 x 序列长度 x 隐藏层大小)。对于 Huggingface，这是每层 (2 x 2 x 序列长度 x 隐藏层大小)。在训练中，整个序列一次性处理（因此 KV 缓存内存 = 0）。
3. Activation Memory = 在前向传播中，每个操作的输出都需要存储以便进行 .backward()。例如，如果您执行 output = Q * input，其中 Q = (dim, dim)，input = (batch, seq, dim)，那么形状为 (batch, seq, dim) 的输出需要存储（以 fp16 格式）。这在 LoRA/QLoRA 中消耗了最多的内存。在大型语言模型中，有许多这样的中间步骤（在 Q、K、V 之后，在注意力之后，在规范化之后，在 FFN1、FFN2、FFN3 之后，在跳层之后...）。每层大约存储 15 个中间表示。
4. Optimizer/Grad memory = 梯度张量与优化器相关的张量占用的内存。
5. Cuda etc. overhead =每次加载 cuda 时，CUDA 占用大约 500-1GB 的内存。此外，当您使用任何量化（如 bitsandbytes）时，会有额外的开销。这里没有直接的公式（我在计算中假设 CUDA 开销为 650 MB）。

Can it run llm https://huggingface.co/spaces/Vokturz/can-it-run-llm

上下文长度与显存占用

quadratic complexity（二次计算复杂度）

Model: 34B-200K

Mode: infer

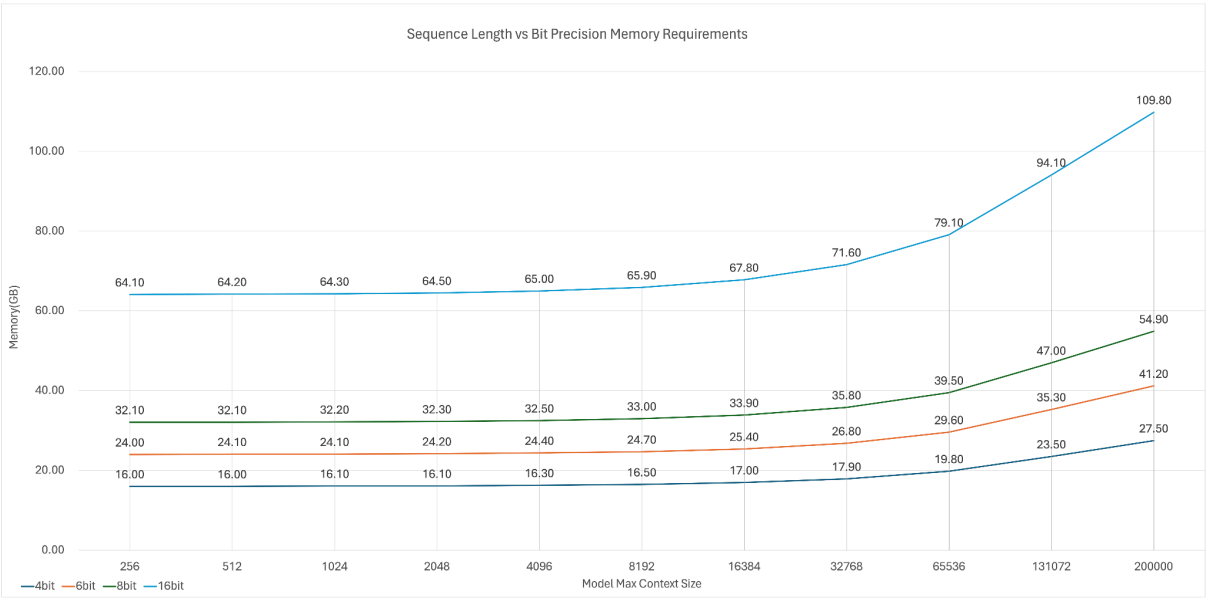

优化

- *FlashAttention 2* https://github.com/Dao-AILab/flash-attention
- *unsloth* https://github.com/unslothai/unsloth
- *Leave No Context Behind: Efficient Infinite Context Transformers with Infini-attention* https://arxiv.org/abs/2404.07143

长上下文与短上下文模型选择

- 准确度优先的任务（例如funcation call）选择短上下文模型（例如4k）
- 可以接受的部分内容遗忘（例如长文本总结任务），选择长上下文模型

Loss-in-the-Middle 问题

https://arxiv.org/abs/2307.03172

- 不进行微调的情况下，将最相关的内容安排在两侧，不太相关的内容安排在中间
- 微调，将与问题相关的内容均匀的分布在整个上下文中 https://github.com/microsoft/FILM